Projet 3

January 27, 2025

1 Projet 3: Identifier les facteurs qui influencent les performances commerciales (Python ou R)

1.1 Problématique métier

Une entreprise souhaite comprendre les interactions entre ses produits, ses performances régionales et ses marges pour optimiser sa stratégie commerciale.

1.2 Objectif

Analyser les relations quali-quali, quali-quanti et quanti-quanti pour détecter des facteurs clés.

1.3 Chargement des bibliothèques

```
[160]: import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
%matplotlib inline
```

1.4 Chargement des données

```
[56]: df_sales.head()
```

[56]:	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID \
	1	CA-2016-152156	11/8/2016	11/11/2016	Second Class	CG-12520
	2	CA-2016-152156	11/8/2016	11/11/2016	Second Class	
	3	CA-2016-138688	6/12/2016	6/16/2016	Second Class	
	4	US-2015-108966	10/11/2015	10/18/2015	Standard Class	
	5	US-2015-108966	10/11/2015	10/18/2015	Standard Class	
	J	05 2015 100900	10/11/2015	10/10/2015	Standard Class	50 20000
	D TD	Customer Name	Segment	Count	ry	City \

Row ID

```
State Postal Code Region
                                                    Product ID
                                                                        Category \
      Row ID
      1
                                       South FUR-B0-10001798
                Kentucky
                                42420
                                                                       Furniture
      2
                Kentucky
                                       South FUR-CH-10000454
                                                                       Furniture
                                42420
      3
              California
                                         West OFF-LA-10000240
                                                                Office Supplies
                                90036
      4
                 Florida
                                33311
                                       South FUR-TA-10000577
                                                                       Furniture
      5
                 Florida
                                 33311
                                       South OFF-ST-10000760
                                                                Office Supplies
                                                                 Product Name \
             Sub-Category
      Row ID
      1
                Bookcases
                                            Bush Somerset Collection Bookcase
      2
                           Hon Deluxe Fabric Upholstered Stacking Chairs,...
                   Chairs
                           Self-Adhesive Address Labels for Typewriters b...
      3
                   Labels
      4
                   Tables
                                Bretford CR4500 Series Slim Rectangular Table
      5
                                               Eldon Fold 'N Roll Cart System
                  Storage
                        Quantity Discount
                 Sales
                                               Profit
      Row ID
      1
              261.9600
                                2
                                       0.00
                                              41.9136
      2
              731.9400
                                3
                                       0.00
                                             219.5820
                                2
      3
               14.6200
                                       0.00
                                               6.8714
      4
              957.5775
                                5
                                       0.45 -383.0310
      5
               22.3680
                                2
                                       0.20
                                               2.5164
         Nétoyage des données
     Valeurs manquantes
[77]: df_sales.columns
[77]: Index(['Order ID', 'Order Date', 'Ship Date', 'Ship Mode', 'Customer ID',
             'Customer Name', 'Segment', 'Country', 'City', 'State', 'Postal Code',
             'Region', 'Product ID', 'Category', 'Sub-Category', 'Product Name',
             'Sales', 'Quantity', 'Discount', 'Profit'],
            dtype='object')
[59]: df_sales.isnull().sum()
[59]: Order ID
                       0
      Order Date
                       0
      Ship Date
                       0
```

1

2

3

4

5

Claire Gute

Claire Gute

Darrin Van Huff

Sean O'Donnell

Sean O'Donnell

Consumer

Consumer

Corporate

Consumer

Consumer

United States

United States

United States

United States

United States

Henderson

Henderson

Los Angeles

Fort Lauderdale

Fort Lauderdale

Ship Mode 0 Customer ID 0 Customer Name 0 Segment Country 0 City 0 State 0 Postal Code 0 0 Region Product ID 0 Category Sub-Category Product Name 0 Sales 0 0 Quantity Discount 0 0 Profit dtype: int64

Il n'y a pas de données manquantes dans notre jeux de données

Lignes douplons

```
[63]: df_sales.duplicated().sum()
[63]: 1
[67]: df_sales.loc[df_sales.duplicated()]
[67]:
                    Order ID Order Date Ship Date
                                                         Ship Mode Customer ID \
     Row ID
      3407
              US-2014-150119 4/23/2014 4/27/2014 Standard Class
                                                                      LB-16795
               Customer Name
                                  Segment
                                                 Country
                                                              City State \
      Row ID
      3407
              Laurel Beltran Home Office United States Columbus Ohio
              Postal Code Region
                                       Product ID
                                                    Category Sub-Category \
      Row ID
      3407
                    43229
                            East
                                FUR-CH-10002965
                                                   Furniture
                                                                   Chairs
                                                   Product Name
                                                                   Sales
                                                                          Quantity \
     Row ID
      3407
              Global Leather Highback Executive Chair with P... 281.372
                                                                               2
              Discount
                        Profit
      Row ID
      3407
                   0.3 -12.0588
```

```
[69]: # suppression des doublons
      df_sales = df_sales.drop_duplicates()
     information sur les données
[72]: df_sales.info()
     <class 'pandas.core.frame.DataFrame'>
     Index: 9993 entries, 1 to 9994
     Data columns (total 20 columns):
          Column
                         Non-Null Count
                                          Dtype
          _____
                          _____
      0
          Order ID
                         9993 non-null
                                          object
          Order Date
                         9993 non-null
                                          object
      1
      2
          Ship Date
                         9993 non-null
                                          object
      3
          Ship Mode
                         9993 non-null
                                          object
      4
          Customer ID
                         9993 non-null
                                          object
      5
          Customer Name
                         9993 non-null
                                          object
      6
          Segment
                         9993 non-null
                                          object
      7
          Country
                         9993 non-null
                                          object
          City
                         9993 non-null
                                          object
          State
                         9993 non-null
                                          object
      10 Postal Code
                         9993 non-null
                                          int64
      11
         Region
                         9993 non-null
                                          object
      12 Product ID
                         9993 non-null
                                          object
          Category
                         9993 non-null
      13
                                          object
          Sub-Category
                         9993 non-null
                                          object
      15 Product Name
                         9993 non-null
                                          object
          Sales
                         9993 non-null
                                          float64
      17
          Quantity
                         9993 non-null
                                          int64
      18
          Discount
                         9993 non-null
                                          float64
      19 Profit
                         9993 non-null
                                          float64
     dtypes: float64(3), int64(2), object(15)
     memory usage: 1.6+ MB
```

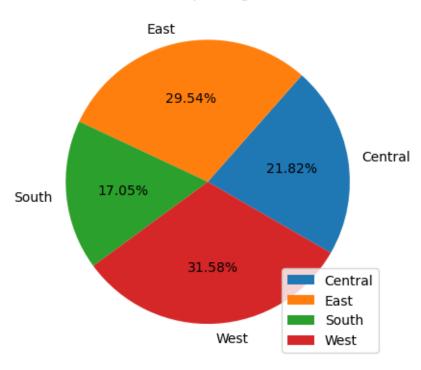
1.6 Analyse des ventes et profits par Région

```
[79]: df_region = df_sales[['Region', 'Sales', 'Profit']]
[87]: df_vente_par_region = df_region.groupby(['Region']).sum().reset_index()
      df_vente_par_region
[87]:
                        Sales
                                    Profit
          Region
      0 Central 501239.8908
                                39706.3625
      1
           East
                 678499.8680
                                91534.8388
      2
           South 391721.9050
                                46749.4303
            West 725457.8245 108418.4489
```

```
[89]: x = df_vente_par_region ['Region']
y = df_vente_par_region ['Sales']

[95]: plt.pie(y,labels =x,autopct='%0.2f%%',startangle=-30)
plt.legend(loc=4)
plt.title('Vente par region')
plt.show()
```

Vente par region

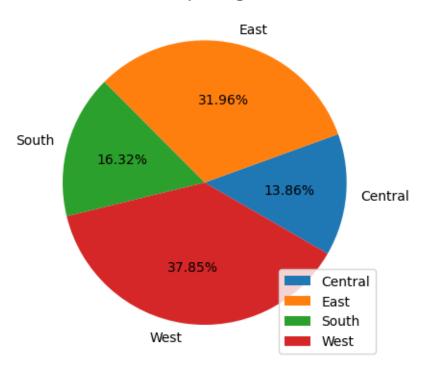


Les régions de l'Est et de L'Ouest sont les régions où les produits sont le plus vendus.

```
[99]: x = df_vente_par_region ['Region']
y = df_vente_par_region ['Profit']

[101]: plt.pie(y,labels =x,autopct='%0.2f%%',startangle=-30)
plt.legend(loc=4)
plt.title('Profit par region')
plt.show()
```

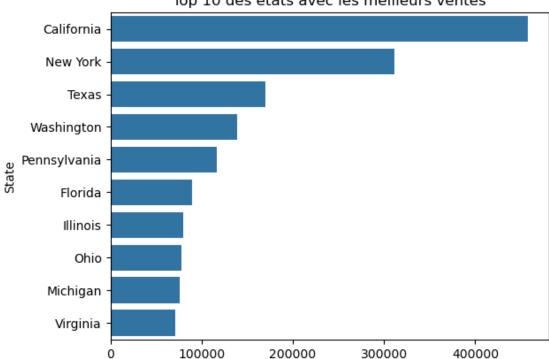




comme attendus les profits sont plus réalisés dans les régions de l'Est et de l'Ouest le Sud et le Centre sont à la traîne par rapport au deux autres régions.

1.7 Analyse des ventes et profits par Etats

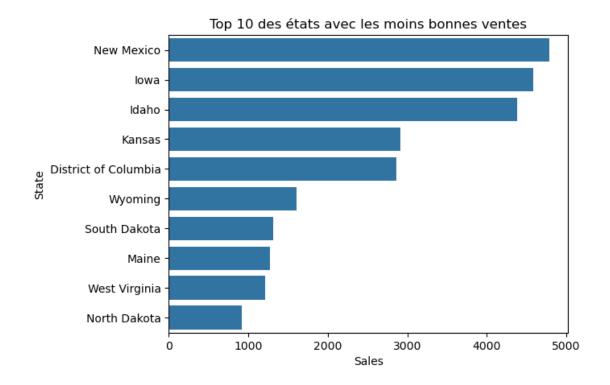
```
[105]: df_etat = df_sales[['State', 'Sales', 'Profit']]
[140]: df_par_etat = df_etat.groupby(['State']).sum().reset_index()
       df_par_etat.head(5)
[140]:
               State
                            Sales
                                        Profit
       0
                       19510.6400
                                     5786.8253
             Alabama
       1
             Arizona
                       35282.0010
                                    -3427.9246
       2
            Arkansas
                       11678.1300
                                     4008.6871
       3
          California
                      457687.6315
                                    76381.3871
                       32108.1180
       4
            Colorado
                                    -6527.8579
[142]: top_vente_par_etat = df_par_etat.sort_values(by = ['Sales'], ascending = False)
       top_vente_par_etat.head(5)
[142]:
                  State
                               Sales
                                           Profit
       3
             California 457687.6315
                                       76381.3871
```



Top 10 des états avec les meilleurs ventes

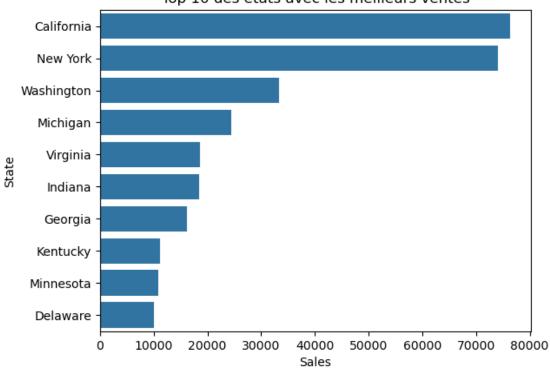
Sales

Nous remarquons que les etats de Californie et de New York sont largement devant en ventes.



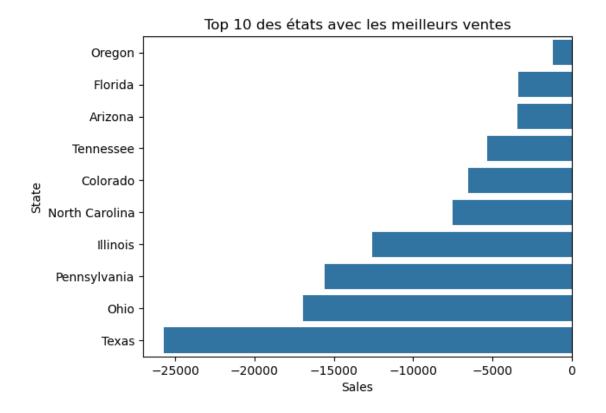
```
[152]: top_profit_par_etat = df_par_etat.sort_values(by = ['Profit'], ascending =__
        →False)
      top_profit_par_etat.head(5)
[152]:
               State
                            Sales
                                        Profit
      3
          California 457687.6315 76381.3871
      30
            New York 310876.2710 74038.5486
      45
          Washington 138641.2700 33402.6517
      20
            Michigan
                      76269.6140 24463.1876
            Virginia
                       70636.7200 18597.9504
      44
[154]: sns.barplot(x=top_profit_par_etat['Profit'].head(10),__

y=top_profit_par_etat['State'].head(10))
      plt.title('Top 10 des états avec les meilleurs ventes')
      plt.xlabel('Sales')
      plt.ylabel('State')
      plt.show()
```



Top 10 des états avec les meilleurs ventes

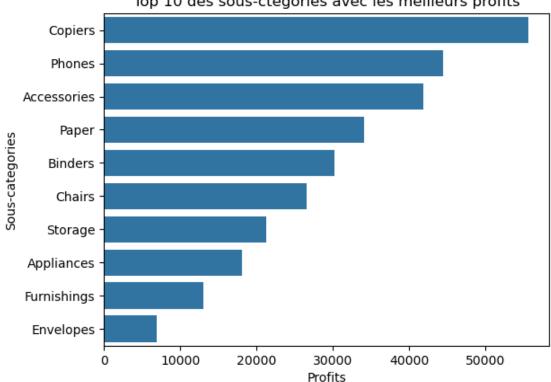
Nous remarquons que les etats de Californie et de New York sont largement devant en Profit avec un écart de l'ordre de 40.000 \$.



1.8 Analyse des ventes et profits par Sous-Catégories

```
[167]: df_sous_categorie = df_sales[['Sub-Category', 'Sales', 'Profit']]
[171]: df_sous_categorie = df_sous_categorie.groupby(['Sub-Category']).sum().
        →reset_index()
       df_sous_categorie
[171]:
          Sub-Category
                               Sales
                                          Profit
                        167380.3180
                                      41936.6357
       0
           Accessories
                        107532.1610
       1
            Appliances
                                      18138.0054
       2
                   Art
                          27118.7920
                                       6527.7870
       3
               Binders
                        203412.7330
                                      30221.7633
       4
             Bookcases
                         114879.9963
                                      -3472.5560
       5
                Chairs
                         328167.7310
                                      26602.2251
       6
               Copiers
                         149528.0300
                                      55617.8249
       7
             Envelopes
                          16476.4020
                                       6964.1767
       8
             Fasteners
                           3024.2800
                                        949.5182
       9
           Furnishings
                          91705.1640
                                      13059.1436
       10
                Labels
                          12486.3120
                                       5546.2540
       11
              Machines
                         189238.6310
                                       3384.7569
       12
                 Paper
                          78479.2060
                                      34053.5693
```

```
13
               Phones 330007.0540 44515.7306
      14
              Storage 223843.6080 21278.8264
             Supplies
      15
                       46673.5380 -1189.0995
               Tables 206965.5320 -17725.4811
      16
[173]: top_profit_par_sous_categorie = df_sous_categorie.sort_values(by = ['Profit'],__
       →ascending = False)
      top10_profit_par_sous_categorie = top_profit_par_sous_categorie.head(10)
[175]: top10_profit_par_sous_categorie
[175]:
         Sub-Category
                           Sales
                                     Profit
              Copiers
                     149528.030 55617.8249
      6
      13
               Phones 330007.054 44515.7306
      0
          Accessories 167380.318 41936.6357
      12
                Paper 78479.206 34053.5693
              Binders 203412.733 30221.7633
      3
      5
               Chairs 328167.731 26602.2251
      14
              Storage 223843.608 21278.8264
      1
           Appliances 107532.161 18138.0054
      9
          Furnishings
                       91705.164 13059.1436
      7
            Envelopes
                       16476.402
                                  6964.1767
[177]: sns.barplot(x=top10_profit_par_sous_categorie['Profit'],
       plt.title('Top 10 des sous-ctégories avec les meilleurs profits')
      plt.xlabel('Profits')
      plt.ylabel('Sous-categories')
      plt.show()
```

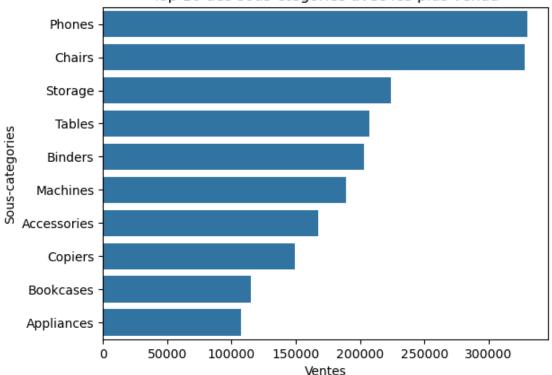


Top 10 des sous-ctégories avec les meilleurs profits

```
[185]: top_vente_par_sous_categorie = df_sous_categorie.sort_values(by = ['Sales'],__
       ⇒ascending = False)
      top10_vente_par_sous_categorie = top_vente_par_sous_categorie.head(10)
     top10_vente_par_sous_categorie
[187]:
[187]:
         Sub-Category
                            Sales
                                      Profit
      13
              Phones 330007.0540
                                  44515.7306
      5
              Chairs 328167.7310
                                  26602.2251
      14
             Storage 223843.6080
                                  21278.8264
              Tables 206965.5320 -17725.4811
      16
      3
             Binders 203412.7330
                                  30221.7633
                                   3384.7569
      11
            Machines 189238.6310
      0
          Accessories 167380.3180
                                  41936.6357
      6
             Copiers 149528.0300
                                  55617.8249
      4
            Bookcases 114879.9963
                                  -3472.5560
           Appliances
                     107532.1610
                                  18138.0054
[191]: sns.barplot(x=top10_vente_par_sous_categorie['Sales'],__
       plt.title('Top 10 des sous-ctégories avec les plus vendu')
```

```
plt.xlabel('Ventes')
plt.ylabel('Sous-categories')
plt.show()
```





1.9 Nombre de clients dans chaque segment

